

Données de défi

Prévision des sinistres liés aux bâtiments
par Generali

Introduction

Classement public

Classement privé

Description

Fichiers donnés aux participants



Challenge compétitif

Sciences économiques

Assurance

Classification

Tabulaires

Moins de 10Mo

Niveau basique

Dates

Commencé le 1 janvier 2019

Contexte

L'assurance habitation est une police d'assurance qui protège la structure de votre maison – les murs, le toit, les planchers et les parties communes – contre les dommages qui pourraient être causés par une inondation ou une tempête, par un incendie ou un acte de vandalisme.

Ce défi fait partie du processus de tarification de l'assurance non-vie, qui comprend souvent deux étapes :

- Modélisation de fréquence, pour déterminer le nombre attendu de réclamations qu'un assureur recevra au cours d'une période donnée ;
- Modélisation de la gravité pour prédire le coût moyen d'une réclamation.

x_train

variables explicatives pour l'entraînement

y_train

variable(s) cible(s) pour l'entraînement

x_test

variables explicatives pour le test

L'organisateur du challenge



Assurance

[SITE WEB DE L'ORGANISATEUR](#)

Mais

L'objectif du défi est de prédire si un bâtiment fera l'objet d'un sinistre d'assurance pendant une période donnée. Il s'agit de prédire la probabilité d'avoir au moins un sinistre pendant la période d'assurance du bâtiment. Le modèle sera basé sur les caractéristiques du bâtiment. La variable cible est :

- - 1 si le bâtiment présente au moins un sinistre sur la période assurée.
- - 0 si le bâtiment n'a pas fait l'objet d'un sinistre sur la période assurée.

Lors de ce défi, vous êtes encouragé à utiliser des données externes. Par exemple : nombre de commerces par code INSEE (code géographique), taux de chômage par code INSEE, météo...

Certaines données peuvent être trouvées sur le site suivant : data.gouv.fr

Description des données

Les données d'entrée contiennent les variables : Identifiant; ft_2_categ; EXPO; ft_4_categ; ft_5_categ; ft_6_categ; ft_7_categ; ft_8_categ; ft_9_categ; ft_10_categ; ft_11_categ; ft_12_categ; ft_13_categ; ft_14_categ; ft_15_categ; ft_16_categ; ft_17_categ; ft_18_categ; ft_19_categ; superficie; ft_21_categ; ft_22_categ; ft_23_categ; ft_24_categ; Insee; target.

Détails

- **Identifiant** : variable permettant d'identifier le client dans notre base de données. Ne pas utiliser pour modéliser. Variable d'identification.
- **ft_2_categ** : année d'observation du contrat assuré.
- **EXPO** : temps assuré chez Generali sur l'année. (Ex : Assurance année entière EXPO = 1 ; 6 mois EXPO = 0,5) Variable numérique.
- **superficie** : superficie en m2 du bâtiment assuré. Variable numérique.
- **Insee** : Code géographique français permettant de localiser le bâtiment assuré. Très utile pour ajouter des données externes. Variable géographique/catégorielle.
- **cible** : variable cible. (0 : aucun sinistre, 1 : au moins un sinistre sur la période assurée).
- autre **ft_i_categ** : caractéristiques anonymisées du bâtiment. Variables catégorielles.

Description du benchmark

Nous avons lancé un benchmark rapide avec un modèle xgboost et obtenu un score NGC de 0,41. Il s'agit d'un modèle basique où toutes les variables catégorielles sont codées par des étiquettes. Les variables les plus importantes sont superficie, ft_22_categ et EXPO.

Les paramètres de xgboost ont été trouvés par validation croisée.

Métrique

La mesure utilisée pour ce défi est le **coefficient de Gini normalisé**.

L'objectif de ce défi est de construire un modèle capable de prédire l'ordre des sinistres. Un modèle est performant s'il détecte avec une probabilité élevée les bâtiments ayant effectivement fait l'objet d'un sinistre.

Pour calculer la métrique, les observations sont classées par probabilité prédite décroissante. Les prédictions ne servent ici qu'à ordonner les observations. Par conséquent, l'ampleur relative des prédictions n'est pas prise en compte dans cette méthode de notation.

Défi Kaggle avec la même métrique : www.kaggle.com/c/porto-seguro-safe-driver-prediction

Challenge data est soutenu par :



[équipe](#) | [conditions d'utilisation](#) | [mentions légales et politique de confidentialité](#) | [Twitter](#) | [LinkedIn](#)